

最优化第三次上机作业

王恒亮 学号：1601210102

本次实现了解决 Minimax Problems 的三种方法，分别为 Least pth Method[?], Smoothing Method[?] 和 Adaptive Smoothing Method[?]。以下分别介绍算法及程序实现，实验结果及分析。

1 算法及程序实现

1.1 Least pth Method

Least pth Method 主要通过优化 U 函数来解决 Minimax 问题，U 函数的定义如下：

$$U(x, u, p, \xi) = \begin{cases} M(x, \xi) \left(\sum_{i \in S(x, \xi)} u_i \left(\frac{f_i(x) - \xi}{M(x, \xi)} \right)^q \right)^{1/q}, & \text{for } M(x, \xi) \neq 0, \\ 0, & \text{for } M(x, \xi) = 0 \end{cases} \quad (1)$$

其中：

$$u_i \geq 0 \quad \text{and} \quad \sum_{i \in I} u_i = 1 \quad (2)$$

$$M(x, \xi) = \max_{i \in I} (f_i(x) - \xi) \quad (3)$$

算法的框架如下：

步 1 取 $p > 1, \xi^{(1)} = 0, u_i^{(1)} = 1, i \in I, x = x^0, r = 1$

步 2 固定 u, p, ξ ，在公式 1 中对 x 取极小，最优解设为 x^r

步 3 更新 u

$$u_i^{r+1} = \frac{v_i^{r+1}}{\sum_{j \in I} v_j^{r+1}}, i \in I$$

其中：

$$v_i^{r+1} = \begin{cases} u_i^r \left(\frac{f_i(x^r) - \xi}{M(x^r, \xi)} \right)^{q-1}, & \text{for } i \in S(x^r, \xi) \\ 0 & \text{for } i \in I - S(x^r, \xi) \end{cases}$$

$$S(x^r, \xi) = \begin{cases} \{i | f_i(x) - \xi > 0, i \in I\}, & \text{if } M(x^r, \xi) \geq 0 \\ I, & \text{if } M(x^r, \xi) < 0 \end{cases}$$

步 4 更新 ξ

$$\xi^{r+1} = \begin{cases} \xi^r + M(x^r, \xi^r), & \text{if } M(x^r, \xi) < 0 \\ \xi^r + \lambda M(x^r, \xi^r) & \end{cases}$$

步 5 更新 $p, p = cp, c \geq 1$, 转至步 2

在实现中, 除了计算出了最优点和最优点的函数值之外, 还记录了迭代次数, 函数调用次数, 具体的参数设置将在结果中说明。

1.2 Smoothing Method

Smoothing Method 是将 Minimax 问题转化为优化近似函数 $f(x, \mu)$, 其定义如下：

$$f(x, \mu) = \mu \ln \sum_{i=1}^m \exp\left(\frac{f_i(x)}{\mu}\right)$$

对于 $f(x, \mu)$ 的优化使用牛顿法求出下降方向, 使用 Armijo 准则找到步长, 在每步迭代后会更新 $\mu, \mu = \beta\mu$ 。对于 $f(x, \mu)$ 的函数, 梯度和 Hessian 矩阵的计算如下：

$$f(x^k, \mu_k) = f(x^k) + \mu_k \ln \sum_{i=1}^m \exp\left(\frac{f_i(x^k) - f(x^k)}{\mu_k}\right)$$

$$\nabla_x f(x, \mu) = \sum_{i=1}^m \lambda_i(x, \mu) \nabla f_i(x)$$

$$\nabla_x^2 f(x, \mu) = \sum_{i=1}^m (\lambda_i(x, \mu) \nabla^2 f_i(x) + \frac{1}{\mu} \lambda_i(x, \mu) \nabla f_i(x) \nabla f_i(x)^T)$$

$$- \frac{1}{\mu} \left(\sum_{i=1}^m \lambda_i(x, \mu) \nabla f_i(x) \right) \left(\sum_{i=1}^m \lambda_i(x, \mu) \nabla f_i(x) \right)^T$$

$$\lambda_i(x^k, \mu_k) = \frac{\exp\left(\frac{f_i(x^k) - f(x^k)}{\mu_k}\right)}{\sum_{j=1}^m \exp\left(\frac{f_j(x^k) - f(x^k)}{\mu_k}\right)}$$

1.3 Adaptive Smoothing Method

Adaptive Smoothing Method 是在 Smoothing Method 的基础对算法做了改进, 主要解决了在 $\mu \rightarrow 0$ 时产生的 ill-condition 问题。Adaptive Smoothing Method 将 Minimax 问题转化为优化公式 4。

$$\Phi_p(x) = \log\left(\sum_{j \in Q} (\exp(pf^j(x)))\right)/p \quad (4)$$

具体算法如下：

步 1 取 $i = 0, k = 0, \gamma = 1$

步 2 设 $\Phi_{p_i,xx}(x_i)$ 是 Hessian 矩阵 R 的 Cholesky 修正, $c(R)$ 为 R 的条件数的倒数, 则若 $\Phi_{p_i,xx}(x_i)$ 正定且 $c(R) \geq k_1, p_i \leq k_3$, 转步 3, 若 $\Phi_{p_i,xx}(x_i)$ 正定且 $c(R) \geq k_1$ 且 $\Phi_{p_i,xx}(x_i)$ 的最大特征值 $\sigma_{p_i,max}(x_i)$ 满足 $\sigma_{p_i,max} \leq k_2$, 转步 3, 否则转步 4

步 3 $h_{p_i}(x_i) = -\Phi_{p_i,xx}(x_i)^{-1} \nabla \Phi_{p_i}(x_i)$, 转步 5

步 4 $h_{p_i}(x_i) = -\nabla \Phi_{p_i}(x_i)$

步 5 计算步长

$$\lambda_{p_i}(x_i) = \max_{l \in N} \{\beta^l |\Phi_{p_i}(x_i + \beta^l h_{p_i}(x_i)) - \Phi_{p_i}(x_i)| \leq \alpha \beta^l < \nabla \Phi_{p_i}(x_i), h_{p_i}(x_i) >\}$$

步 6 $x_{i+1} = x_i + \lambda_{p_i}(x_i) h_{p_i}(x_i)$

步 7 若 $|\nabla \Phi_{p_i}(x_i)|^2 \leq \tau(p_i)$, 转步 8, 否则设 $p_{i+1} = 2p_i, i = i + 1$, 转步 2

步 8 若 $p^* \leq \hat{p}, \gamma = 1$, 其中 p^* 满足 $\epsilon_a(p_i) \leq |\nabla \Phi_{p^*}(x_i)|^2 \leq \epsilon_b(p_i)$, 则设 $\gamma = \max\{2, (\hat{p} + 2)/(k + 1)\}, p_{i+1} = \gamma(k + 2), k = k + 1, i = i + 1$, 否则设 $p_{i+1} = \gamma(k + 2), k = k + 1, i = i + 1$, 转步 2

2 实验结果及分析

本次实验分别在 Xu[?] 中实验中第 2,3 题中的函数和 [?] 中的 Digital filter example 滤波器函数进行结果测试。实验结果如下：

2.1 Xu[?] 中例子 2

问题描述如下：

$$\text{minimize}_{i=1,2,3} f_i(x)$$

其中：

$$f_1(x) = x_1^4 + x_2^2 \quad (5)$$

$$f_2(x) = (2 - x_1)^2 + (2 - x_2)^2 \quad (6)$$

$$f_3(x) = 2 \exp(-x_1 + x_2) \quad (7)$$

初始点取值为 $(1, -0.1)$ ，最优点取值为 $(1, 1)$ 。各个方法的数值结果如表 1。

表 1: Xu 中例子 2			
方法	$ f^* - f $	迭代次数	函数调用次数
Least pth	7.2482×10^{-5}	24	72
Smooth Method	4.3247×10^{-7}	28	57
Adaptive Smooth	4.7311×10^{-5}	43	167

2.2 Rosen-Suzuki Problem

问题描述为：

$$F(x) = x_1^2 + x_2^2 + 2x_3^2 + x_4^2 - 5x_1 - 5x_2 - 21x_3 + 7x_4 \quad (8)$$

$$g_2(x) = -x_1^2 - x_2^2 - x_3^2 - x_4^2 - x_1 + x_2 - x_3 + x_4 + 8 \quad (9)$$

$$g_3(x) = -x_1^2 - 2x_2^2 - x_3^2 - 2x_4^2 + x_1 + x_4 + 10 \quad (10)$$

$$g_4(x) = -x_1^2 - x_2^2 - x_3^2 - 2x_1 + x_2 + x_4 + 5 \quad (11)$$

$$f_2 = F(x) - \alpha_2 g_2(x) \quad (12)$$

$$f_3 = F(x) - \alpha_3 g_3(x) \quad (13)$$

$$f_4 = F(x) - \alpha_4 g_4(x) \quad (14)$$

$$\alpha_2 = \alpha_3 = \alpha_4 = 10 \quad (15)$$

初始值取值为 $(0, 0, 0, 0)$ ，最优解 $x^* = (0, 1, 2, -1)$ 。各个方法的数值结果如表 3。

表 2: Rosen-Suzuki Problem 数值结果

方法	$ f^* - f $	迭代次数	函数调用次数
Least pth	3.6745×10^{-5}	13	39
Smooth Method	1.4665×10^{-10}	47	147
Adaptive Smooth	7.5858×10^{-11}	41	113

2.3 Digital filter example

滤波器函数主要参考了 [?] 中的函数。滤波器函数定义如下：

$$|H(x, \theta)| = A \prod_{k=1}^K \frac{N_k}{D_k} \quad (16)$$

$$A \prod_{k=1}^K \left(\frac{1 + a_k^2 + b_k^2 + 2b_k(2 \cos^2 \theta - 1) + 2a_k(1 + b_k) \cos \theta}{1 + c_k^2 + d_k^2 + 2d_k(2 \cos^2 \theta - 1) + 2c_k(1 + d_k) \cos \theta} \right)^{1/2} \quad (17)$$

其中：

$$x = [a_1, b_1, \dots, c_K, d_K, A]^T \quad (18)$$

$$n = 4K + 1 \quad (19)$$

则对其求导可得 $|H(x, \theta)|$ 对 x 中各个变量的导数。

$$\frac{\partial |H(x, \theta)|}{\partial a_j} = \frac{|H(x, \theta)|}{N_j^2} [a_j + (1 + b_j) \cos \theta] \quad (20)$$

$$\frac{\partial |H(x, \theta)|}{\partial b_j} = \frac{|H(x, \theta)|}{N_j^2} [-1 + 2 \cos^2 \theta + a_j \cos \theta + b_j] \quad (21)$$

$$\frac{\partial |H(x, \theta)|}{\partial c_j} = -\frac{|H(x, \theta)|}{D_j^2} [c_j + (1 + d_j) \cos \theta] \quad (22)$$

$$\frac{\partial |H(x, \theta)|}{\partial d_j} = \frac{|H(x, \theta)|}{D_j^2} [-1 + 2 \cos^2 \theta + c_j \cos \theta + d_j] \quad (23)$$

$$\frac{\partial |H(x, \theta)|}{\partial A} = \frac{|H(x, \theta)|}{A} \quad (24)$$

再对导数求导可以得到其 Hessian 矩阵如下：

(25)

$$\frac{\partial^2 |H(x, \theta)|}{\partial a_j \partial a_k} = \frac{|H(x, \theta)|}{N_j^2 N_k^2} [a_j + (1 + b_j) \cos \theta]$$

(26)

$$\frac{\partial^2 |H(x, \theta)|}{\partial a_j \partial b_j} = \frac{|H(x, \theta)|}{N_j^4} (a_j (\cos \theta - 1) + b_j)$$

(27)

$$\frac{\partial^2 |H(x, \theta)|}{\partial a_j \partial b_k} = \frac{|H(x, \theta)|}{N_j^2 N_k^2} [a_j + (1 + b_j) \cos \theta]$$

(28)

$$\frac{\partial^2 |H(x, \theta)|}{\partial a_j \partial c_k} = -\frac{|H(x, \theta)|}{N_j^2 D_k^2}$$

(29)

$$\frac{\partial^2 |H(x, \theta)|}{\partial a_j \partial d_k} = -\frac{|H(x, \theta)|}{N_j^2 D_k^2} [a_j + (1 + b_j) \cos \theta]$$

(30)

$$\frac{\partial^2 |H(x, \theta)|}{\partial a_j \partial d_j} = -\frac{|H(x, \theta)|}{N_j^2 D_j^2} [a_j + (1 + b_j) \cos \theta]$$

(31)

$$\frac{\partial^2 |H(x, \theta)|}{\partial a_j \partial d_k} = -\frac{|H(x, \theta)|}{N_j^2 D_k^2} [a_j + (1 + b_j) \cos \theta]$$

(32)

$$\frac{\partial^2 |H(x, \theta)|}{\partial b_j \partial b_k} = \frac{|H(x, \theta)|}{N_j^2 N_k^2} (-1 + 2 \cos^2 \theta + a_j \cos \theta + b_j)$$

(33)

$$\frac{\partial^2 |H(x, \theta)|}{\partial b_j \partial c_k} = -\frac{|H(x, \theta)|}{N_j^2 D_k^2} [-1 + 2 \cos^2 \theta + a_j \cos \theta + b_j]$$

(34)

$$\frac{\partial^2 |H(x, \theta)|}{\partial b_j \partial d_k} = -\frac{|H(x, \theta)|}{N_j^2 D_k^2} [-1 + 2 \cos^2 \theta + a_j \cos \theta + b_j]$$

(35)

$$\frac{\partial^2 |H(x, \theta)|}{\partial b_j \partial A} = -\frac{|H(x, \theta)|}{N_j^2 D_j^2} [-1 + 2 \cos^2 \theta + a_j \cos \theta + b_j]$$

(36)

$$\frac{\partial^2 |H(x, \theta)|}{\partial c_j^2} = \frac{|H(x, \theta)|}{D_j^4} (4 \cos \theta - 5 c_j^2 \cos \theta + 3 c_j - 10 c_j \cos^2 \theta - 2 d_j \cos \theta - 2 d_j^2 \cos \theta - 2 d_j \cos^3 \theta - 6 c_j d_j \cos \theta)$$

(37)

$$\frac{\partial^2 |H(x, \theta)|}{\partial c_j \partial d_j} = \frac{|H(x, \theta)|}{D_j^4} (4 \cos \theta - 5 c_j^2 \cos \theta + 3 c_j - 10 c_j \cos^2 \theta - 2 d_j \cos \theta - 2 d_j^2 \cos \theta - 2 d_j \cos^3 \theta - 6 c_j d_j \cos \theta)$$

(38)

$$\frac{\partial^2 |H(x, \theta)|}{\partial c_j \partial d_k} = \frac{|H(x, \theta)|}{D_j^2 D_k^2} [c_j + (1 + d_j) \cos \theta]$$

在实验中逼近函数为 $S(\phi) = |1 - 2\phi|, 0 \leq \phi \leq 1$, 误差函数为 $e(x, \phi) = |H(x, \theta) - S(\phi)|$, 问题转化为 $\min_x \max_{0 \leq \phi \leq 1} |e(x, \Phi)|$ 。 Φ 的取值如下：

$$\Phi = 0.0, 0.05(0.01); \quad i = 1, \dots, 6, \quad (44)$$

$$\Phi = 0.07, 0.46(0.03); \quad i = 7, \dots, 20, \quad (45)$$

$$\Phi = 0.5, 0.54(0.04); \quad i = 21, 22 \quad (46)$$

$$\Phi = 0.57, 0.67(0.1); \quad i = 23, 24 \quad (47)$$

$$\Phi = 0.63, 0.93(0.03); \quad i = 25, \dots, 35, \quad (48)$$

$$\Phi = 0.95, 1.0(0.01); \quad i = 36, \dots, 41 \quad (49)$$

初始点设为 $(0, 1, 0, -0.15, 0, -0.68, 0, -0.72, 0.37)$, 最优解为 $(0., 0.980039, 0., -0.165771, 0., -0.767228, 0., 0.767228, 0.)$ 。各个方法的数值结果如表?? 三种方法的误差曲线图如图 1,2,3。

表 3: 滤波器数值结果

方法	$ f^* - f $	迭代次数	函数调用次数
Least pth	0.0064	7	21
Smooth Method	0.0086	26	105
Adaptive Smooth	0.0078	42	165

2.4 结果分析

在实验中，可以看出以下几点：

- Least pth 方法在几种情况是比较稳定的，而且在几组实验中的迭代次数和函数调用次数均是最少的，而且在滤波器的例子中达到了最优的效果。
- Smooth Method 方法实现比较简单，同时在三组实验中也达到了较不错的效果。
- Adaptive Smooth Method 方法虽然是在 Smooth Method 的基础上进行改进的，但是并不能一定比 Smooth Method 的效果好，但在多数情况下能够比 Smooth Method 在更少的迭代次数和函数调用次数下达到更好的效果。方法的稳定性不如 Least pth 方法。




图 1: Leastpth 误差曲线




图 2: Smooth Method 误差曲线




图 3: Adaptive Smooth 误差曲线